

Практическое задание №4

В практическом задании Вам необходимо продемонстрировать навыки практического использования утилиты `dvc` для работы с данными.

В постановке задачи используется датасет из соревнования Kaggle “Titanic Disaster”, однако Вы можете использовать свои наборы данных, в этом случае в п.п.7-10 необходимо использовать информацию и признаки из вашего датасета.

Этапы задания:

1. Создайте отчет, который снабдите скриншотами последующих действий, в который также поместите ссылку на репозиторий со всеми артефактами, которые возникнут в процессе выполнения задания.
2. Установите `git` и `dvc`.
3. Создайте папку проекта.
4. Настройте папку проекта для работы с `git` и `dvc`.
5. Настройте `git` репозиторий.
6. Настройте удаленное хранилище файлов, например на Google Disk.
7. Создайте датасет о пассажирах “Титаника”, например, `catboost.titanic()`.
8. Создайте датасет, в котором содержится информация о классе (“Pclass”), поле (“Sex”) и возрасте (“Age”) пассажира. Сделайте коммит в `git` и `push` в `dvc`.
9. Создайте новую версию датасета, в котором пропущенные (`nan`) значения в поле “Age” будут заполнены средним значением. Сделайте коммит в `git` и `push` в `dvc`.
10. Создайте новый признак с использованием `one-hot-encoding` для строкового признака “Пол” (“Sex”). Сделайте коммит в `git` и `push` в `dvc`.
11. Выполните переключение между всеми созданными версиями датасета.

При правильном выполнении задания у вас появится `git`-репозиторий с опубликованной метainформацией и папка на Google Disk, в которой хранятся различные версии датасетов.